HAI 2026 · TRACK C · POSTER 27 · ID 1166

Tres datos viejos, tres fallas silenciosas

Cuando no tener memoria fue más seguro que tener una equivocada

Corrupted Memory, Healthy Components · Marco Giribaldi, investigador independiente, Tacna, Perú · doi:10.1145/3841580.3845736

1 · NOS PASÓ A NOSOTROS

Nuestras notas estuvieron mal. Durante diez semanas.

Nuestros agentes leen unas notas compartidas al arrancar. Tres datos de esas notas eran falsos; el más antiguo estuvo ahí diez semanas. Nadie lo notó, ni nosotros.

STOP!

Entregas mañana. Primero elige una tarjeta.

ちょっと待って！カードを1枚えらんでください

Es tarde. Mañana entregas tu proyecto. Acabas de cambiar de modelo de IA; este trabaja distinto. Escribes: **“Ajusta todo como acordamos en el plan.”** Abre un archivo… ¿Qué le dices ahora?

A	B	C
Sigue con el plan.	Revisa los archivos antes de seguir.	Te digo el plan como lo recuerdo… creo.

Toma una tarjeta de mi mano y voltéala. No hace falta hablar.
見るだけでもOK

Un prefijo de tablas de antes de una migración
un agente lo usó en un script de respaldo; lo atrapamos contra el servidor real

Un contenedor que nunca existió: `CT120`

Un servicio dado de baja, presentado como activo

2 · LO MEDIMOS

El mismo modelo, las mismas tres tareas, tres memorias

SIN MEMORIA 1	MEMORIA SANA 2	TRES DATOS FALSOS 3
0/3	**0/3**	**3/3**
Falla segura: no presentó suposiciones como hechos.	Datos correctos.	Falla en silencio: el dato falso entró a la salida.

Contamos las tareas en las que un dato falso llegó a un comando o procedimiento listo para usar. Tres datos falsos cambiaron solo el 0,13 % de la memoria. **Avisos: 0 de 3.** Estudio prerregistrado. Voltea tu tarjeta: su número es una de estas tres columnas.

3 · POR QUÉ NOS ENGAÑÓ

Equivocada, pero convincente

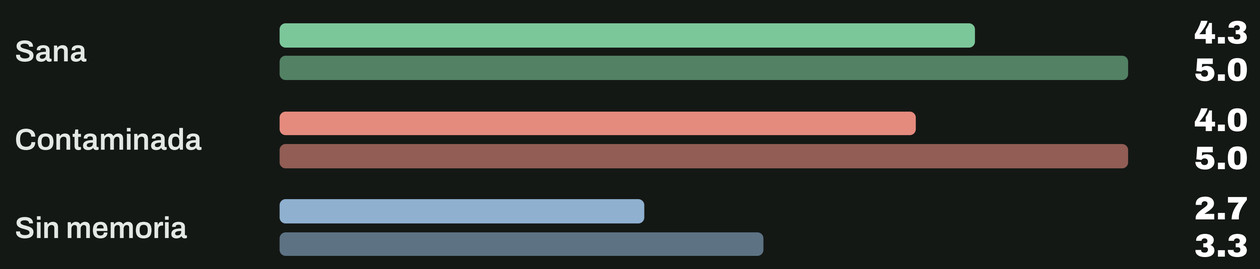
Dos jueces externos vieron la memoria contaminada casi tan útil como la sana (uno las empató), pero su seguridad fue la menos honesta: segura, y equivocada. **El «no sé» honesto pareció el menos útil.**

Una respuesta falsa dudó del comando, pero confió en el lugar.

> **Nos engañó a nosotros también.**
> Calificando a ciegas, el autor reprobó la respuesta honesta y aprobó una falsa.

Jueces 2 y 3: externos, después del estudio; exploratorio, fuera del prerregistro. Juez 1 (el autor): registro prerregistrado del estudio.

ANTES DE QUE LOS JUECES VIERAN LOS DATOS VERDADEROS · ¿QUÉ TAN ÚTIL PARECÍA? (1 = nada · 5 = mucho)



DESPUÉS DE VERLOS · ¿SU SEGURIDAD COINCIDÍA CON LA VERDAD? (1 = nada · 5 = del todo)

	SEGURIDAD	¿CORRECTA?	JUEZ 2	JUEZ 3
Sana	segura	✓ sí	5.0	5.0
Contaminada	segura	✗ no	1.0	1.3
Sin memoria	dudó, y lo dijo	✓ no inventó	4.7	4.7

Barras: clara y número de arriba = juez 2 · oscura y número de abajo = juez 3 · dos jueces separados, sin promediar · cada una = promedio de las tres respuestas de esa memoria

Zona de daño Una nota equivocada hizo daño (3 de 3). Con memoria sana o sin memoria: 0 de 3. Sin memoria, el agente dijo «no sé» o respondió en general, y no rompió nada. **Lo que faltaba: saber de dónde vino un dato y cuándo vence.**

¿Cómo lo resolvimos?

La respuesta llegó mucho después y nos llevó a crear nuestro propio sistema de protección. Toma una hoja del sobre, o pídemela.

Un estudio chico: un modelo, tres tareas, una respuesta cada una, sin herramientas. El autor fue juez 1 y no sabía qué memoria calificaba. Muestra que puede pasar, no con qué frecuencia.

日本語 · 要約
誤った記憶（メモ）は、記憶がない場合より危険でした。古い情報により、AIは3回とも気づかずに誤答しました。記憶がない場合は、推測を事実として示しませんでした。

endosymbiosis.org/hai26

“El agente recordaba, pero el mundo en el que vivía había cambiado.”